МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
“БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ”

Кафедра «Интеллектуальные информационные технологии»

# ЛАБОРАТОРНАЯ РАБОТА №1

по дисциплине «ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ» за 5 семестр

Тема: «Знакомство с анализом данных: предварительная обработка и визуализация»

Выполнил:

студент 3 курса

группы АС-67

Сеглюк К. О.

Проверил:

Крощенко А. А.

2026

**Цель работы:** Получить практические навыки работы с данными с использованием библиотек **Pandas** для манипуляции и **Matplotlib** для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

**Общее задание:**

1. Загрузите данные. Найдите столбец с наибольшим количеством пропущенных значений и удалите его.
2. Провести исследовательский анализ: изучить типы данных, количество пропусков, основные статистические показатели (среднее, медиана, стандартное отклонение).
3. Обработать пропущенные значения (например, заполнить средним значением или удалить строки/столбцы).
4. Преобразовать категориальные признаки в числовые с помощью метода One-Hot Encoding.
5. Выполнить нормализацию или стандартизацию числовых признаков.
6. Построить несколько графиков для визуализации данных (гистограммы, диаграммы рассеяния) и сделать выводы о зависимостях между признаками.
7. **Написать отчет, создать пул-реквест в репозиторий с кодом решения и отчетом в формате pdf.**

**Используемые инструменты:** Python, Pandas, Matplotlib, NumPy, Jupyter Notebook / Google Colab / PyCharm

**Задания по вариантам:**
**Вариант 10**

Выборка German Credit Data. Содержит информацию о заемщиках, включая их кредитную историю, цель кредита, возраст, и оценку кредитоспособности (хороший/плохой).

**Задачи:**

1. Загрузите данные и выведите информацию о них.

```
============================================================
            ИНФОРМАЦИЯ О ЗАЁМЩИКАХ
============================================================

=== ОБЩАЯ ИНФОРМАЦИЯ ===
Всего заёмщиков:       1000
Хороших заёмщиков:     700 (70.0%)
Плохих заёмщиков:      300 (30.0%)

=== ВОЗРАСТ ЗАЁМЩИКОВ ===
Средний возраст:       35.5 лет
Минимальный возраст:   19 лет
Максимальный возраст:  75 лет

=== СУММЫ КРЕДИТОВ ===
Средняя сумма:         3,271.26 DM
Минимальная сумма:     250 DM
Максимальная сумма:    18,424 DM

=== ДЛИТЕЛЬНОСТЬ КРЕДИТОВ ===
Средний срок:          20.9 месяцев
Минимальный срок:      4 месяцев
Максимальный срок:     72 месяцев

=== ЖИЛИЩНЫЕ УСЛОВИЯ ===
own              713 чел. (71.3%)
rent             179 чел. (17.9%)
for free         108 чел. (10.8%)

=== СЕМЕЙНЫЙ СТАТУС И ПОЛ ===
male : single                                548 чел.
female : divorced/separated/married          310 чел.
male : married/widowed                        92 чел.
male : divorced/separated                     50 чел.

=== КРЕДИТНАЯ ИСТОРИЯ ===
existing credits paid back duly till now     530 чел.
critical account/ other credits existing (not  293 чел.
delay in paying off in the past               88 чел.
all credits at this bank paid back duly       49 чел.
no credits taken/ all credits paid back duly  40 чел.
```

```
Заёмщик №1
----------------------------------------
Возраст:           67 лет
Сумма кредита:     1,169 DM
Срок кредита:      6 месяцев
Жильё:             own
Семейный статус:   male : single
Кредитная история: critical account/ other credits existing (not at this bank)
Результат:         Хороший заёмщик

Заёмщик №2
----------------------------------------
Возраст:           22 лет
Сумма кредита:     5,951 DM
Срок кредита:      48 месяцев
Жильё:             own
Семейный статус:   female : divorced/separated/married
Кредитная история: existing credits paid back duly till now
Результат:         Плохой заёмщик

Заёмщик №3
----------------------------------------
Возраст:           49 лет
Сумма кредита:     2,096 DM
Срок кредита:      12 месяцев
Жильё:             own
Семейный статус:   male : single
Кредитная история: critical account/ other credits existing (not at this bank)
Результат:         Хороший заёмщик

Заёмщик №4
----------------------------------------
Возраст:           45 лет
Сумма кредита:     7,882 DM
Срок кредита:      42 месяцев
Жильё:             for free
Семейный статус:   male : single
Кредитная история: existing credits paid back duly till now
Результат:         Хороший заёмщик
```

2. Проанализируйте распределение цели кредита (Purpose). Визуализируйте 5 самых популярных целей.

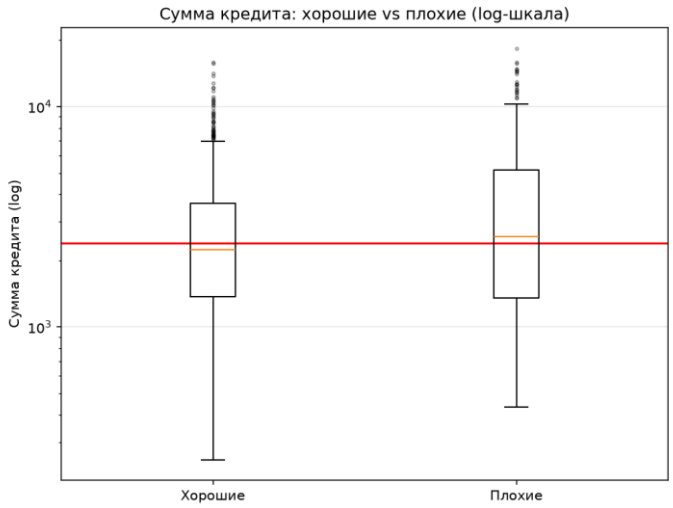
```
purpose
domestic appliances    280
car (new)              234
radio/television       181
car (used)             103
business                97
Name: count, dtype: int64
```

3. Преобразуйте категориальные признаки Sex и Housing в числовой формат.

```
Выбери пункт: 3
<StringArray>
[                    'male : single', 'female : divorced/separated/married',
          'male : divorced/separated',             'male : married/widowed']
Length: 4, dtype: str
<StringArray>
['own', 'for free', 'rent']
Length: 3, dtype: str
=== ДО ===
                  personal_status_sex   housing
0                       male : single       own
1  female : divorced/separated/married       own
2                       male : single       own
3                       male : single  for free
4                       male : single  for free
5                       male : single  for free
6                       male : single       own
7                       male : single      rent
8            male : divorced/separated       own
9               male : married/widowed       own
Sex: {'male : single': 0, 'male : married/widowed': 1, 'male : divorced/separated': 2, 'female : divorced/separate
d/married': 3, 'female : single': 4}
Housing: {'own': 2, 'rent': 1, 'for free': 0}
   personal_status_sex  housing
0                    0        2
1                    3        2
2                    0        2
3                    0        0
4                    0        0
5                    0        0
6                    0        2
7                    0        1
8                    2        2
9                    1        2

Нажми Enter, чтобы вернуться в меню...
```

4. Постройте "ящик с усами" для Credit amount, чтобы сравнить суммы кредитов у "хороших" и "плохих" заемщиков.




```
Выбери пункт: 4
Хороших: 700
Плохих:  300
Всего:   1000
```

5. Создайте сводную таблицу, показывающую средний возраст (Age) и среднюю длительность кредита (Duration) для каждой категории кредитной истории (Credit history).

```
Выбери пункт: 5
                                                средний_возраст  средняя_длительность
credit_history
all credits at this bank paid back duly               36.265306             22.693878
critical account/ other credits existing (not a...    38.436860             19.488055
delay in paying off in the past                       36.136364             26.215909
existing credits paid back duly till now              33.877358             20.111321
no credits taken/ all credits paid back duly          34.300000             27.875000
```

6. Нормализуйте числовые столбцы Age, Credit amount, Duration.

```
======================================================================
                НОРМАЛИЗАЦИЯ ДАННЫХ
======================================================================

=== AGE ===
Минимальное значение: 19
Максимальное значение: 75

=== CREDIT_AMOUNT ===
Минимальное значение: 250
Максимальное значение: 18424

=== DURATION_IN_MONTH ===
Минимальное значение: 4
Максимальное значение: 72

======================================================================
            РЕЗУЛЬТАТЫ НОРМАЛИЗАЦИИ
======================================================================
 Возраст  Возраст_norm  Сумма кредита  Сумма_norm  Срок кредита  Срок_norm
      67         0.857           1169       0.051             6      0.029
      22         0.054           5951       0.314            48      0.647
      49         0.536           2096       0.102            12      0.118
      45         0.464           7882       0.420            42      0.559
      53         0.607           4870       0.254            24      0.294
      35         0.286           9055       0.484            36      0.471
      53         0.607           2835       0.142            24      0.294
      35         0.286           6948       0.369            36      0.471
      61         0.750           3059       0.155            12      0.118
      28         0.161           5234       0.274            30      0.382
```

```
======================================================================
            СТАТИСТИКА ПОСЛЕ НОРМАЛИЗАЦИИ
======================================================================
       age_norm  credit_amount_norm  duration_in_month_norm
count  1000.000            1000.000                1000.000
mean      0.295               0.166                   0.249
std       0.203               0.155                   0.177
min       0.000               0.000                   0.000
25%       0.143               0.061                   0.118
50%       0.250               0.114                   0.206
75%       0.411               0.205                   0.294
max       1.000               1.000                   1.000
```

## Код программы:

```
import pandas as pd
import numpy as np  # часто нужен вместе с pandas
```

```
import matplotlib.pyplot as plt

def show_menu():
    print("""
╔═══════════════════════════════════════════════════════════╗
║                      МЕНЮ ЗАДАНИЙ                         ║
╠═══════════════════════════════════════════════════════════╣
║  1 — Информация о заемщиках                               ║
║  2 — Топ-5 целей кредита (Purpose)                        ║
║  3 — Кодирование Sex и Housing                            ║
║  4 — Boxplot: Credit amount (хорошие vs плохие)           ║
║  5 — Сводная: возраст и длительность по credit_history    ║
║  6 — Нормализация Age, Credit amount, Duration            ║
║  0 — Выход                                                ║
╚═══════════════════════════════════════════════════════════╝
""")

def level1(gerCred):
    print("\n" + "=" * 60)
    print("             ИНФОРМАЦИЯ О ЗАЁМЩИКАХ")
    print("=" * 60)

    total = len(gerCred)
    good = (gerCred['default'] == 0).sum()
    bad = (gerCred['default'] == 1).sum()

    print("\n=== ОБЩАЯ ИНФОРМАЦИЯ ===")
    print(f"Всего заёмщиков:       {total}")
    print(f"Хороших заёмщиков:     {good} ({good / total * 100:.1f}%)")
    print(f"Плохих заёмщиков:      {bad} ({bad / total * 100:.1f}%)")

    print("\n=== ВОЗРАСТ ЗАЁМЩИКОВ ===")
    print(f"Средний возраст:       {gerCred['age'].mean():.1f} лет")
    print(f"Минимальный возраст:   {gerCred['age'].min()} лет")
    print(f"Максимальный возраст:  {gerCred['age'].max()} лет")

    print("\n=== СУММЫ КРЕДИТОВ ===")
    print(f"Средняя сумма:         {gerCred['credit_amount'].mean():,.2f}
DM")
    print(f"Минимальная сумма:     {gerCred['credit_amount'].min():,} DM")
    print(f"Максимальная сумма:    {gerCred['credit_amount'].max():,} DM")

    print("\n=== ДЛИТЕЛЬНОСТЬ КРЕДИТОВ ===")
    print(f"Средний срок:          {gerCred['duration_in_month'].mean():.1f}
месяцев")
    print(f"Минимальный срок:      {gerCred['duration_in_month'].min()}
месяцев")
    print(f"Максимальный срок:     {gerCred['duration_in_month'].max()}
месяцев")

    print("\n=== ЖИЛИЩНЫЕ УСЛОВИЯ ===")
    for name, count in gerCred['housing'].value_counts().items():
        percent = count / total * 100
        print(f"{name:<15} {count:>5} чел. ({percent:.1f}%)")

    print("\n=== СЕМЕЙНЫЙ СТАТУС И ПОЛ ===")
    for name, count in gerCred['personal_status_sex'].value_counts().items():
        print(f"{name:<45} {count:>5} чел.")
```

```
    print("\n=== КРЕДИТНАЯ ИСТОРИЯ ===")
    for name, count in gerCred['credit_history'].value_counts().items():
        print(f"{name[:45]:<45} {count:>5} чел.")

    print("\n" + "=" * 60)
    print("           ПРИМЕРЫ ЗАЁМЩИКОВ")
    print("=" * 60)

    for number, (_, row) in enumerate(gerCred.head(5).iterrows(), start=1):
        status = "Хороший" if row['default'] == 0 else "Плохой"

        print(f"\nЗаёмщик №{number}")
        print("-" * 40)
        print(f"Возраст:           {row['age']} лет")
        print(f"Сумма кредита:     {row['credit_amount']:,} DM")
        print(f"Срок кредита:      {row['duration_in_month']} месяцев")
        print(f"Жильё:             {row['housing']}")
        print(f"Семейный статус:   {row['personal_status_sex']}")
        print(f"Кредитная история: {row['credit_history']}")
        print(f"Результат:         {status} заёмщик")

    print("\n" + "=" * 60)


def level2 (gerCred):
    print(gerCred['purpose'].value_counts().head(5))



def level3 (gerCred):
    # unique метод вывода уникального значения только 1 раз
    print(gerCred['personal_status_sex'].unique())
    print(gerCred['housing'].unique())
    print("=== ДО ===")
    print(gerCred[['personal_status_sex', 'housing']].head(10))
    #метод head являеться методов отображения конкретных строк

    pss_map = {
        'male : single'                         : 0,
        'male : married/widowed'                : 1,
        'male : divorced/separated'             : 2,
        'female : divorced/separated/married'   : 3,
        'female : single'                       : 4,
    }

    housing_map = {
        'own'      : 2,
        'rent'     : 1,
        'for free' : 0,
    }
    print("Sex:", pss_map)
    print("Housing:", housing_map)
    gerCred['personal_status_sex'] =
gerCred['personal_status_sex'].map(pss_map)
    gerCred['housing'] = gerCred['housing'].map(housing_map)
    print(gerCred[['personal_status_sex', 'housing']].head(10))

def level4 (gerCred):
```

```
    good = gerCred.loc[gerCred['default'] == 0, 'credit_amount'] # loc =
условие/метка строки
    bad  = gerCred.loc[gerCred['default'] == 1, 'credit_amount']
    print("Хороших:", len(good))
    print("Плохих: ", len(bad))
    print("Всего:  ", len(good) + len(bad))

    # ——— Boxplot ———
    plt.figure(figsize=(8, 6))
    plt.boxplot([good, bad], tick_labels=['Хорошие', 'Плохие'],
                flierprops=dict(marker='.', markersize=4, alpha=0.4)  )
                # маркер отображения----^ , размерность--^ , ^-прозрачность
    plt.axhline(y=0)
    plt.axhspan( 2400, 2390, color= 'red' )
 #               координаты-^ , ^-размерность
    plt.yscale('log') # log метод делает разницу более наглядной
    plt.ylabel('Сумма кредита (log)')
    plt.title('Сумма кредита: хорошие vs плохие (log-шкала)')
    plt.grid(axis='y', alpha=0.3)
    plt.show()

def level5 (gerCred):
    result = gerCred.groupby('credit_history').agg(
        средний_возраст=('age', 'mean'),
        средняя_длительность=('duration_in_month', 'mean')
    )
    print(result)

def level6(gerCred):
    cols = ['age', 'credit_amount', 'duration_in_month']

    print("\n" + "=" * 75)
    print("                   НОРМАЛИЗАЦИЯ ДАННЫХ")
    print("=" * 75)

    for col in cols:
        min_val = gerCred[col].min()
        max_val = gerCred[col].max()

        # Нормализация Min-Max в диапазон от 0 до 1
        if max_val != min_val:
            gerCred[col + '_norm'] = (
                (gerCred[col] - min_val) / (max_val - min_val)
            )
        else:
            gerCred[col + '_norm'] = 0.0

        print(f"\n=== {col.upper()} ===")
        print(f"Минимальное значение: {min_val}")
        print(f"Максимальное значение: {max_val}")

    print("\n" + "=" * 75)
    print("              РЕЗУЛЬТАТЫ НОРМАЛИЗАЦИИ")
    print("=" * 75)

    result = gerCred[
        ['age', 'age_norm',
         'credit_amount', 'credit_amount_norm',
         'duration_in_month', 'duration_in_month_norm']
```

```
    ].head(10).copy()

    result.columns = [
        'Возраст', 'Возраст_norm',
        'Сумма кредита', 'Сумма_norm',
        'Срок кредита', 'Срок_norm'
    ]

    print(result.round(3).to_string(index=False))

    print("\n" + "=" * 75)
    print("             СТАТИСТИКА ПОСЛЕ НОРМАЛИЗАЦИИ")
    print("=" * 75)

    norm_cols = ['age_norm', 'credit_amount_norm', 'duration_in_month_norm']
    print(gerCred[norm_cols].describe().round(3))

    print("\nНормализация завершена!")
    print("Новые столбцы добавлены в датасет.")

if __name__ == "__main__":
    gerCred = pd.read_csv("german_credit.csv") # подключение к файлу
    while True:
        show_menu()
        choice = input("Выбери пункт: ").strip()
        match choice:
            case '0':
                print("Выход. Пока пока!")
                break
            case '1':
                level1(gerCred)
            case '2':
                level2(gerCred)
            case '3':
                level3(gerCred)
            case '4':
                level4(gerCred)
            case '5':
                level5(gerCred)
            case '6':
                level6(gerCred)
            case _:
                print("Попробуй снова.\n")
                continue

        input("\nНажми Enter, чтобы вернуться в меню...")
        print()
```

**Вывод:** Получил практические навыки работы с данными с использованием библиотек **Pandas** для манипуляции и **Matplotlib** для визуализации. Научился выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.